

基于深度学习的牛津宠物 细粒度分类实验报告

王诗雯 | W125301282 | ResNet-18 / 单变量消融

<https://github.com/Ting-XnX/pet-classifier>

1 任务与实验设置

我使用 Oxford-IIIT Pet 的 37 个宠物品种进行细粒度分类。实际载入 7349 张图像；我合并官方 trainval 与 test，使用 seed=42 分层划分为训练 5144 张、验证 1102 张、测试 1103 张。三部分索引互斥且均覆盖全部类别。本实验采用任务书要求的自定义划分，不与官方测试划分下的成绩直接比较。

我将 ImageNet 预训练 ResNet-18 的分类头替换为 37 类线性层，采用全参数微调。训练输入依次执行 Resize(256)、RandomCrop(224)、随机水平翻转及 ImageNet 标准化；验证和测试采用固定中心裁剪。输入 batch 为 [32,3,224,224]，最后卷积特征为 [32,512,7,7]。

我在 NVIDIA GeForce RTX 5060 Laptop GPU 上运行 PyTorch 2.8.0+cu128。两组均使用 AdamW (lr=0.0001, weight decay=0.01)、batch size=32、10 轮、相同种子和数据顺序；不使用学习率调度及提前终止。仅将交叉熵的 Label Smoothing 系数由 0 改为 0.1。

2 实验结果与消融分析

实验	测试 Top-1	测试 Top-5	Macro-F1	最佳轮次	训练耗时
Baseline	90.21%	99.73%	0.9006	2	6.5 min
LS 0.1	92.11%	98.82%	0.9204	9	5.7 min

我仅按验证 Top-1 选取各组最佳 checkpoint：Baseline 为 92.29%，LS 0.1 为 93.10%。最终测试中，平滑组相对基线的 Top-1 变化为 +1.90 个百分点，Macro-F1 变化为 +0.0198。我将其视为本次固定种子下的观察，不能据此认定统计显著。耗时包含数据加载器初始化，不含下载、测试和报告生成，不作为纯计算性能基准。

我也检查其余指标：两组测试 Top-5 分别为 99.73% 和 98.82%，普通测试交叉熵分别为 0.374 和 0.407。我分别报告各项指标，不将单项改善等同于所有指标同时提升。

2 收敛曲线与结果解释（续）




图1左：统一普通交叉熵；中：训练与验证 Top-1；右：各组实际优化目标。虚线表示验证集。

我的 Baseline 验证准确率由第 1 轮的 88.66% 变为第 10 轮的 92.11%；普通验证交叉熵由 0.505 变为 0.290。我保留验证准确率最高轮次，避免将最后一轮默认视为最优。

我的 LS 0.1 验证准确率由第 1 轮的 89.29% 变为第 10 轮的 92.92%；普通验证交叉熵由 0.560 变为 0.399。我保留验证准确率最高轮次，避免将最后一轮默认视为最优。

我额外记录训练集和普通交叉熵 `train_ce`，因为加入标签平滑后的目标损失与基线损失数值不可直接比较。训练集使用随机增强，训练指标又累积自一轮中不断更新的参数，因而训练与验证差距只能辅助判断过拟合，不能单凭差距定论。

基线后期训练准确率持续上升，而验证准确率未同步改善，出现过拟合迹象。平滑组的验证 Top-1 更高，但训练与验证仍存在差距；仅凭这组曲线，我不能认定过拟合已被消除。

3 混淆品种与错误分析

我按验证成绩选取 `label_smoothing` 展示案例，测试集不参与配置选择。以下按双向误判总数排序，列出最易混淆的三对品种；括号内依次是前者被判为后者、后者被判为前者的样本数。

American Pit Bull Terrier / Staffordshire Bull Terrier：合计 8 次（4 / 4）。

Bengal / Egyptian Mau：合计 7 次（4 / 3）。

Chihuahua / Miniature Pinscher：合计 5 次（5 / 0）。




图2 高频混淆类别局部矩阵（计数）。完整 37 类行归一化矩阵与原始计数另存于 `evaluation` 文件夹；局部图只显示所选类别之间的预测。

3 Grad-CAM 与案例复盘（续）



图 3 预测正确案例：真实类别 Yorkshire Terrier，预测类别 Yorkshire Terrier。样本为固定测试顺序中的第一个预测正确样本。



图 4 预测错误案例：真实类别 Bengal，预测类别 Egyptian Mau。样本为固定测试顺序中的第一个预测错误样本。

我观察到，正确的约克夏犬案例中，热区主要覆盖眼鼻、口部和脸部毛发，背景响应较弱。错误的孟加拉猫案例中，热区仍集中于额头和眼周；图像脸部偏亮，躯干斑纹几乎不可见。因此，这次误判更提示近似品种的面部特征区分不足，而非明显依赖背景。热力图不能证明因果；我还需要更多案例验证这一解释。

4 AI 辅助编程声明与排错复盘

我使用 AI 辅助生成数据管线、训练循环、Grad-CAM 及报告汇总代码，指标和图片均来自实际运行。训练中每批先清零梯度，验证采用 eval() 与 no_grad()，分类头直接输出 logits；Grad-CAM 独立保留梯度。

我在 AI 辅助代码中发现 CUDA 判断不充分：最初仅用 torch.cuda.is_available() 选择显卡。pearl 环境虽返回 True，但 CUDA 12.6 构建不支持 RTX 5060，实际运算报 no kernel image。我用最小张量运算定位问题，改用已有 pearl_gpu（CUDA 12.8），并在 select_device 中加入实际运算与同步检查。复测时不兼容环境明确报错，兼容环境通过。

参考：Oxford-IIIT Pet 数据集（robots.ox.ac.uk/~vgg/data/pets/）；Torchvision ResNet-18 官方文档（docs.pytorch.org/vision/）。完整代码、配置、逐轮 CSV、TensorBoard 和逐样本预测随项目交付。